

架构上下文档位情景 (token)

2048 8192 131072
4096 32768

