



中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

学 校

参赛队号

1.

队员姓名

2.

3.

算力约束下大语言模型的质量评价、资源配置与能力前沿预测

摘要

围绕数据质量、领域配比、模型规模与能力演进的递进关系，本文建立规则明确的质量评价、来源分层的标度律、支持域约束下的资源优化和能力前沿条件预测框架。四问分别使用可比资料建模，并检验结果能否跨来源传递。

针对问题一，使用 A1 固定参考分位把 22 项信号转为规则效用，等权形成 Q_{full} ，并以五维画像解释评分差异。A1 中 commoncrawl 与 arxiv 的 Q_{full} 均值为 0.7600、0.7356；42 项候选中有 7 项统计分歧、3 项领域反转。17 域配比模型在 1M 留出集上使平均 Loss 的 RMSE 由 0.2846 降至 0.2278，13 个响应域全部改善；1B 迁移失败，10B 与 70B 估算外推的中心化误差比分别为 2.3452、2.2672。

针对问题二，B1 八条训练轨迹拟合得到加性 N—D 幂律，衰减指数 $\alpha=0.33997658$ 、 $\beta=0.27987813$ 。整规模留出、前向预测和双维分块的宏 RMSE 分别为 0.000146888、0.000111642、0.000114134。在此基础上推导边际弹性与等 Loss 替代关系；B7 半合成质量表的 45 个单元斜率均为负，共同斜率为 -0.361995。

针对问题三，将题设训练、注意力与质量处理成本统一为 FLOPs，在统计支持域内解析求解并用数值优化核对。参考上下文 2048、质量与配比收益关闭时，预算 10^{19} 、 10^{22} 、 10^{24} FLOPs 对应的最优(N,D)依次为(0.221309,7.049698)、(5.202388,299.893)、(11.965825,299.893)，Loss 依次为 2.998935、2.143211、2.093379；N、D 均以十亿计。两个支持上界依次活跃，高预算平台由支持域产生。

针对问题四，用 C8 六项原始任务得分构造 28 天 90%分位前沿。候选 Loss—Benchmark 桥接在留一规模验证中未优于均值基准，因而直接在能力分数空间预测。主规格的参数关联描述份额为 17.02%，其余 82.98%包含未观测训练量等多种来源。在训练 D 固定及外生正增长参照下，2027 年三档条件中心为 79.76、77.93、76.11，2028 年为 87.13、83.48、79.84。

本文的主要特点是把质量评分与解释画像并报、依据来源和支持域控制模型传递，并分开呈现参数区间、模型范围与外生情景。质量分不是普适训练收益；能力预测距末次观测约 30 和 42 个月，所给区间是条件模型结果，仍需长期同口径数据检验。

关键词：数据质量；领域配比；标度律；约束优化；能力前沿；不确定性

目录

一、引言	3
1.1 问题背景.....	3
1.2 问题重述.....	3
二、问题分析与总体思路	3
三、模型假设	3
四、符号说明	4
五、模型建立与求解	4
5.1 问题一模型的建立与求解.....	5
5.1.1 问题分析与技术路线	5
5.1.2 数据与模型准备	5
5.1.3 模型建立	7
5.1.4 求解与结果分析	11
5.2 问题二模型的建立与求解.....	13
5.2.1 问题分析与技术路线	13
5.2.2 数据与模型准备	13
5.2.3 模型建立	14
5.2.4 求解与结果分析	16
5.3 问题三模型的建立与求解.....	19
5.3.1 问题分析与技术路线	19
5.3.2 数据与模型准备	20
5.3.3 模型建立	20
5.3.4 求解与结果分析	24
5.4 问题四模型的建立与求解.....	28
5.4.1 问题分析与技术路线	28
5.4.2 数据与模型准备	29
5.4.3 模型建立	30
5.4.4 求解与结果分析	33
六、模型检验与分析	36
6.1 误差分析.....	36
6.2 灵敏度分析.....	36
七、模型评价	38
7.1 模型的优点.....	38
7.2 模型的缺点.....	38
八、模型改进与推广	38
8.1 模型的改进.....	38
8.2 模型的推广.....	38
参考文献	38

一、引言

1.1 问题背景

大语言模型训练效果受参数量、数据量、数据内容和领域结构共同影响。扩大模型或增加训练数据通常需要更多算力；提高数据质量与延长上下文也会改变成本。在给定预算下，资源配置因而是一个相互制约的联合决策问题。

经验标度律为规模和数据量的权衡提供了起点[1]。本题还给出文档级质量标注、训练运行级损失和模型级能力评测。本文先辨明各类资料的观测单位，再依次研究质量评价、规模响应、预算配置与能力前沿，使后续推断有可检验的数据基础。

1.2 问题重述

参数量、训练数据量、数据质量和领域配比共同影响训练损失与任务表现；固定算力和上下文开销又限制了可行投入。题目要求先评价数据价值和资源响应，再据此讨论预算分配及未来能力演进。

问题一建立质量评价并检验领域配比响应；问题二刻画规模、数据、质量和配比对损失的关系；问题三在题设成本约束下优化资源配置；问题四研究规模关联、能力前沿和增长放缓情景。四问具有递进关系，其衔接取决于共同量尺与数据支持范围。

二、问题分析与总体思路

四类附件分属文档、训练运行和模型评测三个层次。先在各自量尺中建立可核对的关系，再检验能否把上一问的结果用于下一问。直接拼接不同来源的 Loss，会把来源差异混入质量或技术收益。

技术路线由四条证据链组成：质量信号的规则评价与配比留出检验，B1 内部 N—D 曲面及半合成质量情景，题设成本下的支持域优化，以及同口径评测前沿的独立预测。跨来源系数只在资料提供共同量尺时估计，否则以显式情景呈现。

全文将附件内经验估计、半合成校准和外生条件推演分别报告。桥接或规模迁移检验不通过时，结论留在原资料范围内；这也是四问之间的模型选择结果。

三、模型假设

为明确计算对象和可检验范围，本文采用以下五项假设。相应的适用边界集中在各问结果之后讨论。

假设一：B1 表内的 N、D 和 Loss 可用于估计同来源响应曲面。外部原始运行与验证量尺尚待进一步核对，参数按附件内部关系解释。

假设二：当前标注体系中的五个定向质量信号可用于相应属性描述，固定 A1 参考可用于同体系比较。其余信号通过公布的用途规则计分。

假设三：观测配方附近的领域响应可由线性单纯形对比近似；是否跨规模适用由留出检验决定。

假设四：给定上下文和质量成本形式后，题设 FLOPs 代理定义条件优化问题。统计支持域限定模型可解释的配置范围，预算允许闲置。

假设五：在固定任务组合和筛选规则下，历史高分位可描述合格模型群体；未来投影另依赖趋势、残差扩散和外生增长路径。

四、符号说明

本文使用的主要符号、定义和量纲列于表 1。参数量和训练 token 数统一用十亿为单位，算力成本仍以 FLOPs 表示；能力分数采用六维原始任务分数的 0—100 分量尺。这一约定避免在模型估计和算力优化之间产生 10^9 或 10^{18} 的换算错误。

表 1 主要符号与单位

符号	定义	单位或范围
N, D	参数量、训练 token 数	十亿参数、十亿 token
C, c	总算力预算、 $C/10^{18}$	FLOPs、归一化预算
L_{ctx}, η	外生上下文、注意力系数	token、0.0002/token
p, H	17 域配比、正交对比基	单纯形、 17×16 矩阵
$Q_{full}, W0/W1$	22 项规则构造综合评分、等权/去冗余	[0,1]; 评分约定
u, DQ0	五维描述分位、等权摘要	[0,1]; DQ0 不等同 Q_{full} 或半合成 Q
Q, Q0	半合成质量刻度、参考值	[0.5,1], $Q0=0.5$
L_m, L_B	A 的领域 Loss、B1 的 Loss	各来源原表量尺
L_∞, A, B	幂律截距和两个幅度	对应十亿单位的 Loss 幅度
α, β	N、D 衰减指数	无量纲
h_Q, k_s	质量收益及配比运输系数	情景系数，默认 0
μ	归一预算的乘子	$Loss/10^{18}$ FLOPs
y, F, S, R	能力分、前沿及两个分量	0—100 分量尺；分量可越界
θ_N	能力对 $\log N$ 的关联系数	分/ $\log N$
g_{ref}, ρ	外生对数规模增长参照、增长保留比例	每周、0/0.5/1

五、模型建立与求解

四问均按问题分析、数据准备、模型建立、求解与检验的次序展开。表 2 列出附件用途和相应量尺，为后续图表与数值比较提供索引。

质量资料按文本 ID 去重，配方资料按训练运行索引匹配，B1 按完整轨迹划分验证，能力资料核对模型身份、评测日期与原始任务分数。

表 2 数据用途与限制

资料	主要用途	关键边界
A1—A3 全量 22 信号	质量分布、分歧和扩展比较	文档标注非训练干预
A4—A11 配方与 Loss	训练及同尺度/跨尺度验证	17 输入域、13 响应域；无同运行 Q
A12—A16	估算外推及域映射参考	估算 Loss 不是独立真值
B1 及 B2/B4/B5	源内拟合及分来源检查	轨迹相关，绝对 Loss 不合并
B6/B7 及 B8	半合成质量校准	B6 嵌套于 B7；B8 机制冲突隔离
B9/B10 及 B11/B12	大规模范围与来源说明	估算/元数据不升级成验证
C1/C2/C3/C9	身份、筛选、日期及历史审计	异口径历史不拼接
C4/C7	规模字段和上下文情景	稀疏 D、估计量及架构上限
C5/C6/C8/C10	桥接、逐任务聚合及说明	桥接失败；raw6 量尺独立

对生成机制或共同量尺不明的字段保留原始标记，后续结果分别注明经验估计、半合成校准或条件情景。

5.1 问题一模型的建立与求解

5.1.1 问题分析与技术路线

问题一同时处理文档质量与训练配比。前者把 22 项异构信号转化为可复算的评分，并保留五维解释画像；后者在 17 域配比和 13 个验证领域损失之间估计局部响应。两类资料分开建模，再通过检验决定后续使用范围。

质量模型采用 A1 固定参考分位及预先确定的用途目标；配比模型在单纯形正交坐标上拟合，并以 1M 留出、逐域误差和跨规模压力检验评价。问题一技术路线见图 1。




图 1 问题一技术路线

5.1.2 数据与模型准备

先按竞赛附件[5]和字段数据卡[6]核对质量信号含义。A1—A3 保留 272505 条物理记录的全部 22 项字段；跨表去重后为 261086 个文本 ID。列表字段保留原分量，并按冻结规则生成教育价值、流畅度、无广告程度、清洁度和可读性五个解释坐标。

质量表示分为两层：Q_full 覆盖 22 项信号，回答按既定规则如何评分；五维画像及 DQ0 用于解释评分差异。两层权重与方向均在观察训练 Loss 之前确定，字段合同列于附录 A。

逐项效用使用 A1 训练参考的中秩分位。五个有依据的正向信号采用高分位高效用；其余 17 项以 A1 训练集中 DQ0 最高 20% 文本的逐项中位分位为目标，按接近程度计分。QuRating 四分量先各自转换后合为一项；词数、句数先取 $\log(1+x)$ ；缺失项赋中性值 0.5 并另报实测覆盖数。

设第 j 项参考中的有效数为 n_j ，小于和等于 x 的记录数分别为 $n_{<}(x)$ 、 $n_{=}(x)$ 。中秩分位为 $[n_{<}(x) + n_{=}(x)/2]/n_j$ ，并列记录得到相同分位。A2、A3 沿用这一固定坐标。

$$r_j(x) = \frac{n_{<}(x) + \frac{1}{2}n_{=}(x)}{n_j}, u_j(x) = \begin{cases} r_j(x), & j \in \mathcal{P}, \\ 1 - |r_j(x) - t_j|, & j \in \mathcal{T}. \end{cases}$$

预先固定的六组相关诊断显示，DSIR 三项在 A1—A3 的两两 Spearman 系数均超过 0.99，具有明显冗余；词数与一元熵、句数的相关提示长度混杂。相关符号本身不足以判定语义冲突，图 2 保留有符号数值供后续分类。

Q1 预先选定的六组相关诊断

有符号 Spearman 相关；每列在对应数据层独立计算。

	A1	A2	A3
书籍相似性-百科相似性	+0.999	+1.000	+1.000
书籍相似性-数学相似性	+0.997	+0.994	+1.000
词数-一元熵	+0.951	+0.710	+0.941
数学相似性-词数	-0.913	-0.801	-0.956
词数-句数	+0.829	+0.907	+0.814
流畅度-清洁度	+0.565	+0.248	+0.247

蓝：负相关 浅色：接近零 红：正相关
相关可提示冗余或长度混杂；不能单独证明语义冲突或因果效应。

图 2 六组质量信号的相关性

表 3 质量表示与配比模型的候选比较

对象	候选及本地证据	保留用途	取舍依据
质量表示	五维画像；DQ0；22 项 W0；去冗余 W1	W0 回答综合评分；五维和 DQ0 解释；W1 检查权重	W0/W1 七域次序相同，DQ0 对 arxiv 与 commoncrawl 的排序相反
配比基准 M0	1M 留出 R0 RMSE 0.2846	零信息比较	不利用配比变化

对象	候选及本地证据	保留用途	取舍依据
正交线性 M1	1M 留出 R0 RMSE 0.2278; 13 域均改善	1M 局部主模型	留出证据支持且可逐域解释
岭回归 M2	训练五折分数 0.749715, M1 为 0.750417	正则化敏感性	留出 M2-M1 均方误差区间 跨零, 不升级
非线性 M3	预定残差触发条件未 满足	不拟合	不以留出结果重新启动搜索

W0 对规则效用等权, W1 仅按 A1 内部相关性作去冗余对照, DQ0 保留五维正向属性的摘要。三种表示服务于不同解释目的, 领域次序的差别需在结果中并列呈现。

5.1.3 模型建立

在上述效用坐标上, 主评分 W0 对 22 项等权平均; 对照评分 W1 仅利用参考数据的指标相关结构降低高度重复的权重。记 ρ_{jk} 为 A1 参考样本上的 Spearman 相关系数, 可写出与实施程序一致的权重规则:

$$Q_{\text{full},i} = \frac{1}{22} \sum_{j=1}^{22} u_{ij}.$$

$$a_j = [1 + \sum_{k \neq j} \max(0, |\rho_{jk}| - 0.5)]^{-1}.$$

$$w_j = \frac{a_j}{\sum_{\ell=1}^{22} a_{\ell}}, W1_i = \sum_{j=1}^{22} w_j u_{ij}.$$

当两项效用的绝对 Spearman 相关超过 0.5, W1 相应降低重复信号的权重; Q_{full} 仍以 W0 等权为主。两种权重均未用训练 Loss 反向调节。

逐样本评分按固定参考计算, 领域均值按实际文本数汇总。跨领域汇总须说明采用文本数加权还是领域等权, 两种权重代表不同总体。

表 4 质量评分的领域结果与五维对照

来源领域	文本数	Q_{full} 等权均值	样本 bootstrap 范围	去冗余 W1	DQ0
A1 commoncrawl	9640	0.7600	0.7587—0.7614	0.7469	0.5671
A1 arxiv	1419	0.7356	0.7341—0.7372	0.7454	0.7907
A1 stackexchange	10000	0.7123	0.7113—0.7137	0.7056	0.5524
A1 book	171	0.6738	0.6669—0.6803	0.6812	0.5508
A1 c4	10000	0.6729	0.6711—0.6750	0.6669	0.5058
A1 wikipedia	10000	0.6557	0.6536—0.6576	0.6554	0.5055
A1 github	10000	0.5787	0.5773—0.5801	0.5693	0.3296

来源领域	文本数	Q_full 等权均值	样本 bootstrap 范围	去冗余 W1	DQ0
A2 arxiv 新增 ID	16104	0.7338	0.7333—0.7343	0.7438	0.7868
A3 github 新增 ID	193752	0.5780	0.5776—0.5784	0.5688	0.3304

A1 七域中 W0 与 W1 的点估计次序一致；五维 DQ0 则把 arxiv 排在 commoncrawl 之前，与 Q_full 相反。A2、A3 去重扩展与对应领域均值接近，说明同一标注体系的描述具有一定复现性。两种排序的差别来自评分用途与指标集合，故综合分须与五维解释层并报。

五个核心信号构成正向解释坐标；其余 17 项按公布的用途目标进入 Q_full。词数、句数、文本形态和 DSIR 相似性仍保留原始解释角色，相关或相似不被重复计作独立质量证据。

令 x_{ij} 为文本 i 的第 j 个已定向连续信号， T_j 为 A1 固定训练参考中该信号的有效值集合。用固定经验分布将不同量纲映射为分位坐标，缺失值保留缺失标记。五维均完整时才报告标量摘要，域均值按各信号的有效文本分别计算并保留有效样本数。

$$u_{ij} = \hat{F}_{j,T}(x_{ij}), DQ0_i = \frac{1}{5} \sum_{j=1}^5 u_{ij}. \quad (1)$$

这里参考分布按“小于该值的数量加上等于该值数量的一半”除以有效参考数计算，故并列值取中分位。DQ0 是透明的描述性摘要，不能代替五维质量剖面，也不等同后文半合成表中的 Q。参考分布仅由 A1 训练部分确定，不用 Loss 决定方向或权重。对领域 d 的文档集合 I_d ，定义逐维均值，并同时展示中位数和分位分布。

$$\bar{u}_{dj} = \frac{1}{|I_{dj}|} \sum_{i \in I_{dj}} u_{ij}, I_{dj} = \{i \in I_d : u_{ij} \text{ 有效} \}. \quad (2)$$

图 3 展示五维领域画像。A1 arxiv 的五项平均相对分位约为 0.840、0.752、0.690、0.865、0.807，去重扩展为 0.834、0.748、0.682、0.864、0.806；github 的两层画像也接近。这是同标注体系的描述复现，尚需训练干预验证其效用。

五项核心信号的第一主成分解释约 48.11% 的方差；“无广告”独立成组仅在九个分层中的三个复现。结果支持保留五维主画像，并以 DQ0 作为透明的辅助摘要。



图 3 五维质量的领域画像

本文区分语义目标取舍和已定向信号的统计排序分歧。用同领域文本的中秩分位计算极端分歧率，以 $\tau=0.80$ 为主阈值，并用 0.75、0.90 检验敏感性；同时考察不并列文本对的逆序比例。

$$C_{jk,d}(\tau) = \frac{1}{n_d} \sum_{i \in I_d} J_{ijk}$$

$$J_{ijk} = \mathbf{1}\{(v_{ij} \geq \tau, v_{ik} \leq 1 - \tau)$$

$$\text{or } (v_{ik} \geq \tau, v_{ij} \leq 1 - \tau)\} \quad (3)$$

此处 v 使用分析层自身的中秩，区别于式 (1) 用于跨层比较的固定参考分位 u 。另以两指标均不并列的文本对计算排序逆序比例，检查结论是否被大量并列类别主导。扩展检验按原定义进行，不根据结果再修改质量权重。

42 项候选中确认语义冲突为 0，统计分歧为 7，冗余候选 5，尺度伪象 12，领域反转 3，尚未解决 15。以可读性与无广告程度为例， $\tau=0.80$ 时 A1、A2 去重扩展、A3 去重扩展的极端分歧率分别为 8.811%、13.332%、8.676%。分类结果表明综合评分需要明示用途，五维层仍须呈现相反评价。

原文检查还解释了 A1 中部分 n -gram 比例超过 100 的现象：重复 n -gram 重叠计数字符后，分子可以大于全文字符数。对应记录保留原值，不机械裁剪。A2、A3 的全部生成链未被独立核实，这一解释不外推为所有异常都已经消除。

质量标注表与训练配方表缺少同运行质量配对，故分别建立描述质量与配比预测两条证据链。配比实验的研究背景见 RegMix[7]；本文独立使用附件运行估计自己的冻结参数。A4/A5 按运行索引匹配得到 512 组训练配方。 p 为 17 维非负配比，分量和为 1；各分

量不独立增加。成分数据分析强调这种闭约束[2]。本题零配比较多，使用欧氏单纯形的正交对比，不使用需要处理零值的对数比坐标，也不把它称为 ILR。

令 H 为固定的 17×16 Helmert 正交基，训练均值为 $\bar{p}$ 。以列向量约定写出模型 M1：

$$H^T H = I_{16}, H^T \mathbf{1} = 0, z = H^T(p - \bar{p})$$

$$\hat{L}_m(p) = a_m + \beta_m^T z \quad (4)$$

对 13 个验证领域分别用最小二乘估计截距 a_m 和系数 β_m 。正交化消除配比总和与截距的精确共线性，同时保留原始零值。M0 为每个领域的训练均值。平均响应 R_0 用于总体比较，完整的 R_3 向量用于防止平均改进遮蔽某一领域恶化。

$$R_0(p) = \frac{1}{13} \sum_{m=1}^{13} \hat{L}_m(p), R_3(p) = (\hat{L}_1(p), \dots, \hat{L}_{13}(p)). \quad (5)$$

17 个配比在同一配方内求和为一，增加某一领域必然意味着减少其他领域。正交基 H 把配比相对训练平均值的变化投影到 16 维空间，既去掉和为一造成的精确共线性，也保留原始零配比。式 (4) 中的回归系数只刻画已观察配方附近、特定验证领域的局部关联；若沿某一领域转入另一领域，需要同时考察 13 个响应，而不能只依据平均损失。

设 t_j 为指定参考画像在第 j 项的固定分位目标， $\hat{F}_j$ 为 A1 训练参考的中秩经验分布。对没有通用原值方向的字段，逐样本目标接近效用和等权综合分写为：


$$u_{ij}^{\text{target}} = 1 - |\hat{F}_{j,A1}(x_{ij}) - t_j|, Q_i^{W0} = \frac{1}{22} \sum_{j=1}^{22} u_{ij}. \quad (6)$$

分位映射只消除原始量纲，不能单独决定语义方向；逐项目标分位的公布使 Q_{full} 可复算，也使其用途依赖性明确。对于五个正向信号，单项效用改用较高分位对应较高效用的规则。W1 的训练内去冗余权重与完整字段合同一同保存，正文不将 W1 重新估计为基于验证 Loss 的最优权重。

领域评分需检验表示方式对排序的影响。图 4 并列 W0、W1 和五维 DQ0 的 A1 七域次序：前两者相近，而五维摘要反转 arxiv 与 commoncrawl 的相对位置。A2、A3 去重扩展用于同体系复核。

Q1 领域排序与评分规则

A1七域；三列各自排序。排序不是训练收益真值。



A2/A3非重叠扩展均值与对应A1领域接近；仅属同标注体系复现。

图 4 质量评分规则下的领域排序

5.1.4 求解与结果分析

训练阶段五折综合分数分别为 M0 1.001578、M1 0.750417、M2 0.749715；M2 的惩罚参数在训练阶段确定。参数与验收规则在读取 A6—A11 留出 Loss 前冻结，M3 升级条件未触发。A7 用于预定候选验收。

表 5 与图 5 给出主要留出结果。1M 下 M1 平均响应 RMSE 为 0.2278，低于 M0 的 0.2846；13 个领域均改善，逐域 RMSE 平均由 0.7129 降至 0.4540。M1–M0 均方误差差的成对 bootstrap 区间为 $[-0.03949, -0.01893]$ ；M2 相对 M1 的差异区间跨零，因此保留较简洁的 M1。

表 5 配比模型的留出验证及适用边界

规模与样本	M0 R0 RMSE	M1 R0 RMSE	中心化误差比 M1/M0	解释
1M, 256 组	0.2846	0.2278	0.8012	同尺度关联有效，13 域均改善
60M, 256 组	不作绝对预测 验收	不作绝对预测 验收	0.8876	部分中心化形状迁移
1B, 64 组	不作绝对预测 验收	不作绝对预测 验收	3.108	中心化迁移失败




图 5 1M 留出样本的逐领域预测误差

跨规模时分别中心化观测与预测，仅比较配比响应的相对形状。60M 的误差比为 0.8876，呈部分迁移；1B 达到 3.108，明显劣于常数基准。A6 与 A8 使用同一组配比，几何支持证据不重复计数。

经验支持由训练配比的凸包、最近邻距离及训练分位阈值判断。1M 的 256 个配比中仅 2 个严格落在训练凸包内，252 个处于预定近邻层，2 个为域外。近邻预测有证据，并不意味着整个单纯形都有可信预测。对 A12 配比/A13 估算 Loss 和 A14 配比/A15 估算 Loss 另外按 index 成对连接，分别为 10B/70B 的 63 个运行。冻结 M1 未重拟合，只比较中心化响应形状、排序与训练几何支持。表 6 给出补充结果。

表 6 A12—A15 估算外推压力检验

估算规模	中心化 RMSE 比 M1/M0	预测与估算 R0 秩相关	方向一致率	严格训练凸包内
10B, 63 组	2.3452	-0.4494	30.16%	63/63
70B, 63 组	2.2672	-0.5122	31.75%	63/63

10B、70B 估算表的 13 域平均中心化误差比分别为 1.7295、2.1613；配比与训练点虽有重合，响应形状仍失配。两组估算 Loss 只用于压力检验，与 1B 迁移失败共同限定 M1 的使用范围。

问题一得到可复算的 22 项综合评分、多维画像和 1M 附近的配比响应。质量评价是规则定义，配比收益是局部留出关联；后续质量情景与资源优化分别处理这两条证据链。

图 6 汇总 1M、60M、1B 及 10B/70B 估算表的中心化误差比。1M 局部成立、60M 部分迁移，1B 与估算外推失配；后续模型不继承通用跨规模配比系数。




图 6 配比响应的跨规模误差

5.2 问题二模型的建立与求解

5.2.1 问题分析与技术路线

问题二先用 B1 的八条完整轨迹估计 N—D 响应，再检验弹性、替代和分组预测。B7 提供半合成质量斜率，A 表提供局部配比响应；两项均作为独立的条件扩展。问题二技术路线见图 7。




图 7 问题二技术路线

5.2.2 数据与模型准备

B1 包括八个参数规模、每个规模 147 个检查点，共 1176 行；N 与 D 分别以十亿参数、十亿 token 计。模型估计和验证均保留完整轨迹结构。

以规模轨迹为留出单位，避免同一训练路径的检查点同时进入训练和测试。B2、B4、B5 只比较各自来源内部的中心化响应形状。

五参数形式分别表示 Loss 底值、参数与数据衰减幅度及各自指数，并与零响应、对数线性基准比较。12 组预定初值收敛至相同极小值；Jacobian 秩为 5，条件数约 33.83，说明本附件内的数值拟合稳定。

5.2.3 模型建立

在 B1 同一量尺中，按完整轨迹等权的均方误差估计加性幂律[1]；各轨迹行数相同，因此与逐行均方误差等价。正幅度和正指数保证模型内资源增加时预测 Loss 下降且边际改善递减。

$$L_B(N, D) = L_\infty + AN^{-\alpha} + BD^{-\beta}. \quad (7)$$

L_∞ 是给定量尺上的渐近截距；A、B 是以十亿为单位时两个衰减项的幅度； α 、 β 是衰减指数。正幅度与正指数表达资源增加时 Loss 降低且边际改善递减，不证明现实训练完全满足加性可分离。表 7 给出估计及整轨迹重抽样的条件分位区间。

表 7 幂律参数与 200 次整轨迹重抽样区间

参数	估计	2.5%分位	97.5%分位
L_∞	1.68979756	1.68963	1.68997
A	0.35398032	0.353758	0.354119
B	1.24030558	1.24017	1.24043
α	0.33997658	0.339808	0.340137
β	0.27987813	0.279824	0.279934

代入参数得到本文最终采用的附件内部基线：

$$\hat{L}_B = 1.68979756 + 0.35398032N^{-0.33997658} + 1.24030558D^{-0.27987813}. \quad (8)$$

参数与误差适用于 B1 附件量尺。Pythia 公开研究说明受控训练轨迹的用途[3]，但本附件的原始运行、验证语料和 tokenizer 尚未完全追溯，外部校准有待新证据。

令 $U=AN^{(-\alpha)}$ 、 $V=BD^{(-\beta)}$ 。对式（7）求导并按总 Loss 归一化：

$$\frac{\partial L_B}{\partial N} = -\frac{\alpha U}{N}, \frac{\partial L_B}{\partial D} = -\frac{\beta V}{D}$$

$$\varepsilon_N = -\frac{\alpha U}{L_B}, \varepsilon_D = -\frac{\beta V}{L_B} \quad (9)$$

总 Loss 弹性随资源位置改变，不能直接写成 $-\alpha$ 、 $-\beta$ 。两个自身二阶导数均为正，表明模型内绝对边际改善递减。等 Loss 曲线满足：

$$\frac{d\log D}{d\log N} = -\frac{\alpha U}{\beta V}$$

$$D_{\text{new}} = \left(\frac{B}{L_{\text{old}} - L_\infty - AN_{\text{new}}^{-\alpha}} \right)^{1/\beta} \quad (10)$$

有限替代要求式（10）右端分母为正，且新配置仍位于支持范围。图 8 给出总 Loss 弹性；边际导数和等 Loss 替代分别由式（9）、式（10）及数值示例说明。在 $N=1$ 、 $D=100$ 时预测 Loss 为 2.385578，N 与 D 的总 Loss 弹性为 -0.050447 、 -0.040100 ，等 Loss 对数替代率为 -1.258018 。N 减少至 0.8 时 D 约需 135.5586；减少至 0.5 时 D 约需 315.8275，已超过支持上限 299.893。




图 8 参数与数据对总 Loss 的弹性

比较参数和数据的边际作用，必须把指数与幅度项和当前位置一起计算。令 $U=A N^{(-\alpha)}$ 、 $V=B D^{(-\beta)}$ ，则单位 N 与单位 D 的绝对边际改善之比为：

$$\frac{|\partial L_B / \partial N|}{|\partial L_B / \partial D|} = \frac{\alpha A}{\beta B} N^{-\alpha-1} D^{\beta+1}. \quad (11)$$

因此 $\alpha=0.33997658$ 大于 $\beta=0.27987813$ ，只说明两个衰减项各自对其资源的指数，不说明增加一单位参数一定比增加一单位数据更重要。 U 与 V 的幅度、 N 和 D 当前值、资源单位及每单位成本共同决定实际边际收益。若比较按百分比变动，应采用总 Loss 弹性 $\alpha U/L_B$ 与 $\beta V/L_B$ ；若比较等 Loss 的 N — D 替代，则使用二者比值并检查有限替代式的分母和支持范围。

图 9 并列 B1 八条轨迹的观测、拟合和残差。三类分组留出误差共同支持附件内部加性曲面的规则性；密集检查点属于同一训练过程，外部预测仍需共同量尺检验。




图 9 B1 训练轨迹的拟合与残差

5.2.4 求解与结果分析

同一轨迹的检查点高度相关，不能随机拆行制造独立样本。采取三类验证：整规模留出，每次用其余规模训练；前向预测，分别用前 73 和前 110 个数据规模点训练；N-D 双维分块，用其余七个规模的前 98 点预测未见规模的后 49 点。表 8 与图 10 显示幂律模型相对于均值和对数线性对照的结果。

表 8 三类轨迹验证的宏平均 RMSE

验证方式	均值基准	对数线性	幂律模型	幂律最坏组
整规模留出	0.351306	0.117987	0.000146888187	0.000220230
前向预测	0.271274	0.120386	0.000111641982	0.000176509
双维分块	0.290069	0.122919	0.000114133980	0.000189630




图 10 标度律的分组验证误差

三类留出均满足预定的 B1 内部用途容差。极端规模留出含单侧外推，其余规模主要是插值。200 次整轨迹重抽样均有效，但原始轨迹只有八条，参数分位反映固定模型与当前资料的条件波动。

B2、B4、B5 来源内中心化误差相对零响应基准的中位比分别为 0.855084、0.436601、0.555135。B3 为派生插值；B9/B10 的四条 D=0 记录不预测，另 128 条估算 Loss 只用于外推范围说明。

B6 为 B7 的精确子集，不重复计数。B7 的 450 个唯一 N—D—Q 点构成 45 个单元，单元内 Q—Loss 斜率全为负，共同斜率-0.361995。加入规模调节后，留一规模的中心化宏 RMSE 由 0.052964 降至 0.043679，检验的是半合成表内形状。

用独立情景层表达四因素关系，既回答题目中的质量与配比机制，也保留未被数据识别的部分：

$$L_s(N, D, Q, p) = L_B(N, D) - h_Q(Q - Q_0) + k_s(N) \Delta L_A(p), h_Q = \lambda 0.3619952862. \quad (12)$$

$Q_0=0.5$ ， λ 取 0、0.5、1、1.5。 ΔL_A 为 A 来源中相对于参考配比的 R0 变化； k_s 还包含 A/B Loss 量尺转换，无法由现有数据估计。默认基线为 $h_Q=0$ 、 $k_s=0$ 。由此广义式在参考质量与配比处退化为式 (7)；非零质量项和跨来源配比项只作为明确假定的情景，不以拟合符号冒充已经识别的统一规律。

表 9 质量与跨来源证据的可解释范围

项目	数值结果	适用解释
B7 共同质量斜率	-0.361995, 45/45 为负	半合成表内校准
质量规模调节验证	0.052964→0.043679	中心化响应形状
B2/B4/B5 误差比	0.855084/0.436601/0.555 135	来源分开的事后形状诊断
Q 提高 0.1 的示例替代	N 减 24.903% 或 D 减 30.210%	$\lambda=1$ 及量尺运输假设下的条件结果

质量与规模的等 Loss 替代由式 (12) 求导；在固定 h_Q 、固定配比的条件下，

$$\frac{d \log N}{dQ} = -\frac{h_Q}{\alpha U}, \frac{d \log D}{dQ} = -\frac{h_Q}{\beta V}, N_{\text{new}} = \left(\frac{A}{U+h_Q \Delta Q} \right)^{1/\alpha}. \quad (13)$$

表 9 的替代示例取 $N=1$ 、 $D=100$ 、 $\Delta Q=0.1$ ，分别固定另一资源计算。Q 使用 B7 情景刻度；不同有效数据机制即使匹配局部斜率，也会给出不同的有限替代，因此该示例按条件情景解释。

领域替代必须沿单纯形切向进行。将领域 j 的 δ 比例转给领域 i ，对第 m 个验证领域的变化为：


$$\Delta L_m = \delta(e_i - e_j)^T H \beta_m, \mathbf{1}^T(e_i - e_j) = 0. \quad (14)$$

M1 的配比代理对单纯形切向变化给出局部关联。1B 迁移失败且严格凸包支持仅 2/256，非零跨来源系数 k_s 缺少可估量尺。问题二据此形成 B1 幂律主干，以及分别标注来源的质量、配比条件扩展。

图 11 展示 200 次整轨迹重抽样的五参数条件分位及 α — β 联合波动。所有重抽样有效且参数未触及边界；窄参数带只反映 B1 规则曲面和固定加性形式。

Q2 整轨迹重抽样参数稳定性

200次；左为五参数相对主估计的条件分位，右为 α — β 联合散点。



窄带仅说明八条附件轨迹及所选加性幂律下的数值稳定，不代表外部泛化区间。

图 11 幂律参数的整轨迹重抽样

图 12 上半部分显示 B7 单元质量斜率随 N、D 的变化，下半部分在假定运输系数下计算有限替代。Q 由 0.5 升至 0.6、 $\lambda=1$ 时，N 或 D 的减少比例各自固定另一资源，不相加为总节约。




图 12 B7 质量响应与条件替代

问题二的主结果是 B1 量尺中的 N—D 曲面及边际替代。B7 斜率刻画半合成质量响应，A 表配比关联限定于局部；后续预算基线仅使用已验证的 B1 曲面。

5.3 问题三模型的建立与求解

5.3.1 问题分析与技术路线

问题三在给定 FLOPs 预算下配置参数量、训练数据量和条件情景中的质量投入。先统一成本单位与统计支持域，再用解析解确定基线配置，以数值解核对，并比较成本形式、上下文和配比情景。问题三技术路线见图 13。

预算是上限，达到 N、D 统计支持界后可以闲置。由此可区分内点配置、数据上界活跃及双上界平台；这些是模型约束状态，不是现实训练收益的终点。




图 13 问题三技术路线

5.3.2 数据与模型准备

训练、注意力和质量处理成本均采用题设形式。N、D 以十亿计，前两项换算乘 10^{18} ，按 token 支付的质量成本乘 10^9 ；上下文 L_{ctx} 作为外生档位， $\eta=0.0002$ ，参考 $Q_0=0.5$ 为情景值。

$$C_{used} = 10^{18}(6 + \eta L_{ctx})ND + 10^9 D[g(Q) - g(Q_0)]_+ \leq C. \quad (15)$$

三种题设质量成本分别为：

$$g_{exp}(Q) = 10^7 e^{6Q}, g_{pow}(Q) = 5 \times 10^9 Q^4, g_{log}(Q) = 2 \times 10^9 \log(1 + 10Q). \quad (16)$$

g 的单位为 FLOPs/token。三个成本项使用相同 D，不将筛选前后 token 再计算一次。以上是题设算力代理，并非现实货币成本或 GPU 账单。独立领域价格和实际可供数量没有被识别，不能添加虚构价格。定义 $c=C/10^{18}$ 、 $k=6+\eta L_{ctx}$ 、 $r(Q)=[g(Q)-g(Q_0)]_+/10^9$ ，则成本约束化为 $[kN+r(Q)]D \leq c$ 。

主规格关闭质量收益与配比运输，最小化 B1 内部 Loss。支持域为 $N \in [0.070542, 11.965825]$ 、 $D \in [0.134, 299.893]$ ；Q 固定 0.5，p 取训练均值。矩形表示统计范围，内部并非每点都有独立实验。

$$\frac{d \log N^*}{d \log C} = \frac{\beta}{\alpha + \beta}, \frac{d \log D^*}{d \log C} = \frac{\alpha}{\alpha + \beta}. \quad (17)$$

5.3.3 模型建立

固定上下文且质量成本增量为零时，目标随 N、D 增大而下降。若两支持上界都可承担，直接取两上界；否则预算紧约束给出 $ND=K=c/k$ 。代入幂律并令 $x=\log N$ 后，目标的非恒定部分严格凸，内点由唯一一阶条件确定：

$$\mathcal{L} = L_B + \mu(kND - c), \alpha AN^{-\alpha} = \beta BD^{-\beta}, \mu \geq 0, \mu(kND - c) = 0. \quad (18)$$

由此得到无界内点，并投影到由上下界及预算共同确定的区间：

$$N_0 = \left(\frac{\alpha A}{\beta B}\right)^{1/(\alpha+\beta)} K^{\beta/(\alpha+\beta)}$$

$$a_N = \max(N_{min}, K/D_{max}), b_N = \min(N_{max}, K/D_{min})$$

$$N^* = \text{clip}(N_0, a_N, b_N), D^* = K/N^* \quad (19)$$

式 (19) 仅用于预算紧且可行区间非空的情形；若 $K < N_{min} D_{min}$ 则不可行。该推导同时说明内点 N、D 对预算的弹性分别为 0.451522、0.548478。表 10 给出参考上下文 2048、质量收益与配比运输均关闭时的三个代表配置。

表 10 题设预算下的基线资源配置

预算 C FLOPs	N* 十亿参数	D* 十亿 token	预测 Loss	约束状态
10^{19}	0.221309	7.049698	2.998935	预算紧约束
10^{22}	5.202388	299.893	2.143211	D 支持上界活跃
10^{24}	11.965825	299.893	2.093379	两支持上界活跃，预算闲置

51 档预算、每档四个 SLSQP 初值共 204 次对照均成功，解析解与数值解的最大目标差为 4.86×10^{-13} ，最大投影 KKT 残差为 2.78×10^{-17} 。这核验了条件优化问题的求解精度。

按活跃约束定义结构转移。图 14 显示，预算约 9.325359×10^{21} 时 D 先达到 299.893；约 2.300064×10^{22} 时 N 和 D 同时达到支持上界。此后模型内 Loss 为 2.093379， 10^{24} 预算只使用约 2.3001%。平台来自支持域约束。




图 14 基线资源配置与 Loss 路径

情景目标为 $L_B - h_Q(Q - 0.5)$ ， $Q \in [0.5, 1]$ ， h_Q 取 B7 校准幅度的 0、0.5、1、1.5 倍。它把明确假定的质量收益接到题设成本上，全部属于条件情景。固定 Q 时，由 $D = \min(D_{\max, c} / [kN + r(Q)])$ 消元；在预算紧段，N 满足：

$$-\alpha A N^{-\alpha} + \beta B \left(\frac{kN+r}{c} \right)^\beta \frac{kN}{kN+r} = 0. \quad (20)$$

左侧负项随 N 增大而趋近零，正项严格递增，故固定 Q 只有一个内点解或边界解。外层质量问题可能非凸：先检查端点和 101 个固定网格点的所有局部谷，再作区间精化，并以 201 点加密及每情景三个 SLSQP 初值核对。

表 11 相同收益假设下的三类质量成本比较

成本形式	N^*	D^*	Q^*	预测 Loss
指数型	0.276246	4.666434	0.674774	2.980638
幂函数型	0.224408	6.869602	0.506789	2.998908
对数型	0.361029	2.835817	1.000000	2.935776




图 15 质量成本情景的最优路径

表 11 对比 10^{19} 预算、2048 上下文和参考收益 $h_Q=0.361995$ 下的结果。图 15 展示完整条件投入路径。成本形式改变机会成本，因而即使采用相同收益假设，也可能给出几乎不投入、中等投入或直接投向上界的不同质量选择。

μ 为归一预算的正乘子。小幅提高质量的局部启动条件为 $h_Q > \mu D r'(Q_0)$ ，但在非凸问题中它不能决定有限幅度投入是否划算。令 $L_{ND}^*(c, Q)$ 为给定 Q 时尚未扣除质量收益的最小基线 Loss，全局启动阈值为：

$$h_{\text{crit}}(c) = \inf_{Q > Q_0} \frac{L_{ND}^*(c, Q) - L_{ND}^*(c, Q_0)}{Q - Q_0}. \quad (21)$$

候选包括 Q 趋于 Q0 的极限。10¹⁹ 预算下，对数成本的局部门槛为 0.472240，全局门槛为 0.235678；参考收益 0.361995 介于二者之间，因此小幅投入不优，直接投向 Q=1 却可能更优。1377 个条件配置的 4131 个数值起点中，17 个落入较差局部解，4 个线搜索失败；每个配置仍至少有一个成功解与嵌套结果一致，最坏差 1.29×10⁻¹²。失败起点保留在输出中，不将此比较写成任意非凸函数的形式全局证明。

固定 Q 后的一维 N 问题只有唯一内点或边界解；质量外层可出现不同局部谷。数值求解因此检查端点、网格和多组初值，选取与加密网格一致的条件解。

图 16 和表 12 按两个支持界阈值呈现 51 档预算路径。固定上下文 2048 且质量收益关闭时，已使用算力内部的训练与注意力比例不随预算发生转移；高预算总份额变化来自预算闲置。

表 12 基线预算路径的活跃约束与成本结构

预算区间或代表点	活跃约束	N、D 的响应	预算解释
低于 9.325359×10 ²¹	预算紧约束	N、D 均按内点弹性增长	基础训练约 93.61%，注意力约 6.39%，质量增量为零
约 9.325359×10 ²¹ 至 2.300064×10 ²²	D 支持上界及预算约束	D=299.893，主要增加 N	固定上下文下成本份额不变
高于 2.300064×10 ²²	N、D 两支持上界，预算松弛	N=11.965825，D=299.893	实际使用约 2.300064×10 ²² FLOPs；10 ²⁴ 点仅用约 2.3001%

Q3 预算使用与支持约束转移

51档预算；基础情景 Q=0.5、上下文2048，质量增量成本为零。




图 16 预算构成与支持界转移

有限的支持范围是证据边界而非现实供应上限。若把 D 的允许上界压为原值的四分之一或二分之一，高预算平台 Loss 分别变为 2.212525 与 2.147192；这只是在未知供应条件下的压力情景。不能把 299.893 十亿 token 解释成产业数据总量，也不能把预算平台外推为实际算力投资的永久零收益。

5.3.4 求解与结果分析

基线资源配置首先由 B1 曲面和题设成本确定。配比收益在主规格中取零：A 来源的局部响应虽可用于有限候选比较，但跨规模运输证据不足。

另在 A 来源中比较 513 个有限候选：训练平均配比 $\bar{p}$ ，以及 $\bar{p}$ 与每个训练配比的中点。每个候选都有明确非负凸组合权重，处于观测凸包内；仍检查 13 域响应，不仅检查平均 Loss。最小平均响应候选的中心化变化约 -0.353773 ，但仅 10 域改善、3 域恶化。它是给定候选集和 1M 关联模型内的条件选择，现实供应尚未核实，不能宣布为可部署配方或接到 B1 绝对 Loss 上。

C7 的架构元数据给出 2048、4096、8192、32768、131072 五档最大上下文。它们作为外生成本情景，不解释为所有模型真实采用的训练窗口。题设代理直接给出：

$$\frac{c_{\text{attn}}}{c_{\text{train}}} = \frac{\eta L_{\text{ctx}}}{6}, L_{\text{crit}} = \frac{6}{\eta} = 30000. \quad (22)$$

30000 是两个成本项相等的解析位置，不是实测训练阈值；固定上下文时该比例不随预算改变。10¹⁹ 预算下，上下文由 2048 增至 131072，基线 N 从 0.221309 降至 0.106754、D 从 7.049698 降至 2.907819、Loss 从 2.998935 升至 3.367161。这是只计成本的比较，目标函数没有独立的长上下文能力收益项，因而不能直接据此建议缩短真实系统的上下文。

归一预算的边际价值满足 $dL^*/dC = -\mu/10^{18}$ 。内点 $\mu = \alpha U/c = \beta V/c$ ；D 上界活跃而 N 可变时为 $\alpha U/c$ ；两支持上界且预算松弛时为零。这不是现实算力的市场价格。支持界放宽可能有正边际收益，但域外预测需要新的证据，不能将局部导数视为外部性能保证。

保留 Q2 的 200 个联合五参数向量，以五档上下文和 51 个预算传播，共得到 51000 个条件配置。没有把各参数的边际区间独立组合。图 17 分开显示参数数值敏感性和收益机制情景范围。例如参考低预算的参数条件区间约为 $N \in [0.221249, 0.221387]$ 、 $D \in [7.047196, 7.051612]$ 、 $\text{Loss} \in [2.998852, 2.998986]$ ；很窄是附件规则曲面的结果。质量、成本和配比情景包络不具有抽样置信区间含义，两类范围均不覆盖全部来源与模型错误。




图 17 参数传播与机制情景范围

主规格的配置对应 B1 支持域和题设 FLOPs 成本。以下质量、上下文与配比比较均在各自明示的条件下报告。

在 10^{19} 预算和对数质量成本下，局部启动门槛约 0.472240，全局门槛约 0.235678；参考条件收益 0.361995 处于两者之间。图 18 显示小幅增加 Q 与有限跃迁的不同判断，这是半合成收益接入题设成本后的条件机制。




图 18 质量投入的局部与全局门槛

图 19 给出五档外生上下文的成本敏感性。 10^{19} 预算下，上下文从 2048 增至 131072，基线 Loss 由 2.998935 升至 3.367161；模型目标中没有另计长上下文的能力收益。成本项相等的 $L_{ctx}=30000$ 由 $6/\eta$ 解析得到。




图 19 上下文成本敏感性

图 20 区分预算约束的影子价与质量上界的边际价值。基线 10^{19} FLOPs 处归一预算乘子约 0.020096，有限差分与解析值相差约 4.73×10^{-13} ；两支持上界活跃后乘子为零。




图 20 预算与质量的影子价

问题三给出可复核的基线预算路径和条件质量、配比及上下文情景。参数传播带反映 B1 源内稳定性，机制包络反映收益搬运、成本形式与支持域选择；两类不确定性分别解释。

5.4 问题四模型的建立与求解

5.4.1 问题分析与技术路线

问题四先从同口径原始任务分数构造历史前沿，再检验 Loss—能力桥接、参数关联和动态外推。桥接未通过留一规模比较，因此能力预测直接使用评测分数。问题四技术路线见图 21。




图 21 问题四技术路线

图 22 将 853 条合格模型的六项原始得分均值与 28 天 90% 分位并列；前沿由 2024 年 6 月的 36.453 升至 2025 年 3 月的 52.333。该分位刻画近期较高表现的筛选群体，允许随样本构成回落。




图 22 C8 六任务能力前沿

六任务能力变化并不均衡。图 23 左栏按相同原始量尺列出端点增量，MATH Lvl 5 约增加 34.02 分，MUSR 约增加 2.53 分；右栏是同一描述回归规格下的参数关联分量。两栏分别反映任务变化与统计关联。

Q4 六任务前沿的端点变化

同一28天 q90 规则；两栏采用不同横轴量尺。

	六任务前沿增量 ΔF (分)	参数关联分量 ΔS (分)
IFEval	22.34	1.52
BBH	13.82	3.88
MATH Lvl 5	34.02	2.12
GPQA	4.75	1.77
MUSR	2.53	1.96
MMLU-PRO	14.48	3.74

蓝：观测前沿端点变化 红：当前回归规格的参数关联描述分量

ΔS 不是完整规模贡献；剩余变化也不能归为纯技术因果效果。

图 23 六任务前沿变化及参数关联

5.4.2 数据与模型准备

C8 提供逐任务评测，C1 提供模型身份与参数，C9 用于可用性和异常筛选。按完整 ID、参数差异不超过 2%、六任务完整、已报告许可证、模型可用及无异常标记筛选，得到 853 条主样本：基础预训练 92 条、对话或微调 539 条、合并 221 条、其他 1 条。

日期采用评测文件时间。C1 中 81 个重复 ID 对应的 162 行整组排除；C8 的 1958 个文件中 4 个截断文件记入审计但不解析，每个模型目录取最新可解析记录。C3 早期分数与主分析量尺不同；C4 训练 D 记录稀少且口径混合。

令 b_{ik} 为模型 i 的六类原始任务得分，综合能力采用等权平均。IFEval 取两种 strict 准确率平均；BBH、GPQA、MUSR 取组 acc_norm ；MATH 取 $exact_match$ ；MMLU-PRO 取 acc 。它与 C1 的归一化 Average 不同。

$$y_i = \frac{1}{6} \sum_{k=1}^6 b_{ik}, F_t = Q_{0.90}\{y_i: t - 28 \text{ 天} < t_i \leq t\}. \quad (23)$$

按六项原始任务得分等权形成 0—100 分能力值，再取每个 28 天窗口的 90% 分位，窗口至少包含 15 个模型。2024-06-16 至 2025-03-14 的前沿增量为 15.87965 分。该定义区别于 C1 归一化 Average，也区别于全生态累计最高纪录。

为检验前面三问的 Loss 能否转成此处的能力分数，先建立线性与按 Loss 排序的单调候选，并设置训练组均值作为零信息基准。高可比的七个 Pythia 规模采用留一规模验证；对每个被留出的规模 i ，仅以其余六条拟合候选映射并计算预测误差，宏均方根形式为：

$$RMSE_{\text{Loso}}(f) = \sqrt{\frac{1}{7} \sum_{i=1}^7 [b_i - \hat{f}_i(L_i)]^2}. \quad (24)$$

七个相对可比的 Pythia 规模上，线性和单调候选的留一规模 RMSE 分别为 0.552834、0.436635，均高于均值基准 0.424448。满足主样本 C1 参数一致性的只有两条，图 24 展示候选拟合与留出误差。检验结果不支持将 B1 Loss 数值转换为 C8 能力分数。




图 24 Loss—Benchmark 桥接检验

因此 Q2、Q3 的 Loss 保留原附件量尺，Q4 在 C8 任务分数空间独立预测。负向桥接检验决定了四问如何衔接。

5.4.3 模型建立

C6 为主桥接表，C5 仅作嵌套对照，75 行与 43 行不相加。本文实际建立并比较候选 Loss-Benchmark 线性映射 $Benchmark = a + b \cdot Loss$ 和按 Loss 排序的单调插值映射，并以训练组均值为零信息基准；方向、拟合和留一规模误差在原单位单独报告。附件仅将七个 Pythia 模型列为高可比，且属于同一家族；即使其 Loss 与 B1 末检查点一致，外部验证语料、tokenizer 和配对时点也未完全核实。表 13 给出高可比组的留一规模结果。

表 13 高可比桥接组的留一规模预测误差

桥接方法	RMSE	检验对象
均值基准	0.424448	七个高可比规模
线性桥接	0.552834	七个高可比规模
单调插值	0.436635	七个高可比规模

主样本 853 条记录中仅九条训练 D 非空；同时满足同阶段 N、D 与 C4 compute 可用定义的只有六条。完整 N—D 贡献由此无法估计。本文先以类型和家族效应控制的回归描述参数关联。

$$y_i = a + \theta_N \log N_i + \gamma t_i + \delta_{\text{type}(i)} + \xi_{\text{family}(i)} + \epsilon_i. \quad (25)$$

式 (25) 中的时间以年计。 θ_N 是对参数规模的关联系数，区别于标度律中的 β 。对产生 F_t 的两个排序邻点使用完全相同的分位插值权重 w_{it} ，定义 $S_t = \theta_N \sum_i w_{it} \log N_i$ ， $R_t = F_t - S_t$ 。权重只在相应两个点非零，合为 1，故端点分解满足恒等式：

$$\Delta F = \Delta S + \Delta R, \pi_N = \frac{\Delta S}{\Delta F}, \pi_R = 1 - \pi_N. \quad (26)$$

主规格 $\theta_N = 4.595943$ ，参数关联分量增加 2.703245 分，调整残差增加 13.176404 分，分别占前沿增量的 17.0233% 和 82.9767%。图 25 展示这两个描述分量；后者包括未观测训练 D、算法、架构、后训练、家族构成和评测波动。




图 25 前沿变化的参数关联分解

表 14 显示参数关联比例对筛选和起点敏感：只保留已知家族、严格许可证或较晚起点时可变为负值。固定端点、仅重抽系数得到的条件区间为[13.90%,23.00%]，与这些定义变化分别报告。

表 14 分解的控制规格与敏感性

规格或筛选	参数关联份额	解释
仅参数规模回归	17.78%	描述性对照
时间与类型控制	16.71%	汇总样本关联
进一步控制家族	17.02%	主规格
只保留已知家族	-15.92%	分解反号
严格许可证	-26.82%	分解反号
2024 年 9 月后起点	-75.89%	端点和时间范围敏感

各家族时间趋势并不一致。六条可用基础模型上的 $raw6 = \text{截距} + b_N \ln N + b_D \ln D$ 仅作描述性敏感性；留一实体后系数大幅波动，结果不运输到 853 条前沿样本。

表 15 C4 训练数据与算力字段的识别范围

范围	样本数	描述性结果	完整规模贡献
853 条主样本中 D 非空	9	含估算或后训练口径	无法计算
可用同阶段 N/D/compute	6	$\ln N$ 系数 2.409; $\ln D$ 系数 1.180	不能外推到 853 条
compute 与 6ND 大致相合	5	$\ln N$ 系数 9.037; $\ln D$ 系数 4.677	单实体口径敏感
六条留一实体	每次 5 条	$\ln N$: -5.286 至 9.037; $\ln D$: -0.490 至 4.677	符号及幅度不稳定
另有 C4 compute 的 base 模型	16	$\ln(\text{compute})$ 关联斜率 2.637	混家族/估算字段，仅作诊断

六条之一的 C4 compute 与 6ND 代理相差约 4.584 倍，口径没有充分对齐；五条筛选只为敏感性，不是重定主样本。由此能回答的是指定样本与前沿定义下的参数关联与未解释剩余分量，完整 scale 贡献、独立 non-scale 技术效果及真实算力放缓效应仍不可识别。

预定比较持续性、截断线性、有界 logit 线性和最近 13 周局部 logit 四种动态模型。以至少 16 个历史周端点训练并滚动预测，现有资料只允许 4 周 20 折和 13 周 11 折回测；表 16 报告各模型 MAE。

表 16 前沿模型的回溯滚动验证

模型	4 周 MAE	13 周 MAE
持续性	1.995689	3.683316
截断线性	1.763472	1.564437
有界 logit 线性	1.756586	1.529283
最近 13 周局部 logit	1.914621	2.867412

按可用期限等权平均 MAE 选择有界 logit 线性模型。其形式为：

$$z_t = \log \frac{F_t/100}{1 - F_t/100} = a_F + b_F t + e_t$$

$$\hat{F}_{t+h} = \frac{100}{1 + \exp[-(\hat{a}_F + \hat{b}_F(t+h))]} \quad (27)$$

logit 反变换使预测留在 0—100 分量尺内，不构成真实能力饱和的经验结论。固定历史中点的分段趋势未得到信息准则支持，故保留单趋势。

滚动窗口重叠，折次不独立；资料保留的是模型最新评测记录，尚非完整历史榜单快照。因此回测属于现有资料下的拟样本外检验。

主规格参数关联份额为 17.02%，但家族和筛选群体改变后可出现不同方向。图 26 并列同家族趋势与 2027 年条件中心的群体敏感性，供解释全局时间系数。




图 26 家族趋势与群体敏感性

5.4.4 求解与结果分析

预测原点为 2026-09-25，末次观测为 2025-03-14，相隔 560 天。2027-09-25 和 2028-09-25 分别距末次观测约 30 和 42 个月；表 17 与图 27 同时给出目标日期、条件中心、条件模型区间和独立的模型范围。

表 17 未来能力的条件预测及独立的模型范围

目标日期	条件中心	条件模型 95%预测区间	四模型中心范围
2027-09-25	79.76	[61.24,90.40]	52.17—83.77
2028-09-25	87.13	[69.58,95.57]	52.33—97.11




图 27 能力前沿的条件预测

条件模型区间由四周循环残差块重抽样构造[4]：1000 次重抽后重新估计冻结模型，并按残差标准差乘 $\sqrt{1+h/4}$ 的假定扩散规则加入未来扰动。95%分位只对应这一模型与扩散设定。

表 17 最后一列为四个预定动态模型的中心预测范围，用于显示模型选择敏感性；它与前一列的条件模型区间含义不同。

外生放缓情景另取透明的正增长参照。历史前沿排序邻点的插值 $\ln N$ 在 2024-06-16 至 2025-03-14 两端相差 0.588181，跨 38.714 周，端点斜率为每周 0.015193。若从预测原点起假设训练 D 固定且 $C \approx 6ND$ ，此路径作为参考对数 compute 增长；全时段参数分量趋势 -0.029739 分/周并未被改写为正向经验增长。

$$\hat{F}_\rho(h) = \text{clip}\{U(h) - (1 - \rho)\theta_N g_{\text{ref}} h, 0, 100\}, \rho \in \{1, 0.5, 0\}. \quad (28)$$

$\rho=1$ 为原动态模型条件中心， $\rho=0.5$ 和 0 为外生增长保留比例。用 $\theta_N=4.595943$ 分/ $\ln N$ 在能力分数空间平移参考路径，表 18 给出 2027、2028 两期限的条件中心。

表 18 外生算力增长保留情景下的条件中心

目标日	$\rho=1$ 参考中心	$\rho=0.5$ 中度放缓	$\rho=0$ 强放缓	参考正增长关联增量
2027-09-25	79.76	77.93	76.11	3.6409 分
2028-09-25	87.13	83.48	79.84	7.2918 分

表 18 不给未来情景分配概率；表 17 的条件 95%区间只对应 $\rho=1$ 。固定训练 D 和正增长端点路径均属外生设定，情景差值按假设路径解释。

现有动态验证覆盖 4 周和 13 周，logit 模型 MAE 分别为 1.7566、1.5293；26 周和 52 周没有可用折次。图 28 并列四种预定模型的滚动误差与条件覆盖，显示长期区间尚缺同期限检验。





图 28 前沿模型的滚动验证

原规模代理采用全时段非正的参数分量趋势，三条放缓路径因此重合。图 29 改用另行声明的正增长端点参照，并固定训练 D；灰蓝区间仍只属于 $\rho=1$ 原模型。

Q4 外生算力放缓的条件中心

训练D固定， $C \approx 6ND$ ； ρ 为参考正增长的保留比例。



灰蓝线仅用于 $\rho=1$ ；情景差异不是实际算力因果效应。

图 29 外生增长放缓情景

两期限的参考中心为 79.76、87.13；中度放缓为 77.93、83.48；强放缓为 76.11、79.84。差异是冻结参数关联系数作用于外生路径的条件结果；实际能力还会随训练 D、算法和评测规则变化。

六、模型检验与分析

6.1 误差分析

本节按真正留出的单位汇总检验。Q1 留出训练运行，Q2 留出规模轨迹与前向块，Q3 比较解析和数值解，Q4 对现有历史端点作短期滚动回测。误差保留原附件量尺，表 19 列出各问的检验对象和结论范围。

Q1 的 1M 留出 RMSE 由 0.2846 降至 0.2278，13 域均改善；1B 中心化误差比为 3.108，限定跨规模使用。Q2 三类分组宏 RMSE 依次约为 0.000146888、0.000111642、0.000114134，支持 B1 附件内部曲面的规则性。

Q4 桥接的线性、单调候选 RMSE 为 0.552834、0.436635，均高于均值基准 0.424448；能力预测改用原始任务分数。前沿模型仅有 4 周和 13 周回测，未来 12 和 24 个月条件区间尚无同期限覆盖检验。

Q3 的最大解析—数值目标差为 4.86×10^{-13} ，属于求解精度检查；没有独立真实最优配置作外部标签。各问的检验单位、比较基准和未覆盖对象见表 19。

对象与估计证据	留出或核验设计	关键本地结果	可支持结论	未覆盖的外部问题
Q1 22 项规则分；A1 训练参考	A2/A3 剔除重叠 ID 作同体系扩展	arxiv Q_full 0.7356/0.7338; github 0.5787/0.5780	领域描述近似复现	非独立人工真值或训练收益
Q1 M1；512 组训练配比	A7 的 256 组 1M 运行、13 响应域	R0 RMSE 0.2846→0.2278; 13/13 域改善	同尺度局部关联	60M 部分、1B 失败；10B/70B 仅估算
Q2 五参数律；八条完整轨迹	留一规模、前向、N—D 双维分块	宏 RMSE 0.000146888/0.000111642/0.000114134	B1 附件内部曲面	外部 Loss 量尺与真实训练波动
Q3 51 档预算；题设成本代理	解析与 204 次数值起点及 KKT 核对	最大目标差 4.86×10^{-13} ；残差 2.78×10^{-17}	条件最优求解精确	真实价格、供应及域外收益
Q4 七条高可比桥接	留一规模；均值为零信息基准	均值 0.424448，线性 0.552834，单调 0.436635	桥接未通过	跨来源 Loss 到 raw6 的运输
Q4 四种动态模型	4 周 20 折、13 周 11 折滚动	选中模型 MAE 1.7566/1.5293	短期回溯比较	26/52 周及 12/24 月经验覆盖

总体上，Q1 支持局部配比关联，Q2 支持来源内曲面，Q3 支持题设条件下的数值最优性，Q4 的桥接检验阻断 Loss 到能力分数的直接换算。

6.2 灵敏度分析

质量评价比较 W0、W1 与五维 DQ0：前两者在 A1 七域点估计次序一致，五维摘要则反转 arxiv 与 commoncrawl 的相对次序。分歧阈值 0.75、0.80、0.90 用于检查统计分类的稳健性。

预算配置对机制设定更敏感。同一半合成质量收益下，指数、幂函数和对数成本的条件最优 Q 约为 0.675、0.507、1.000；上下文由 2048 增至 131072 时， 10^{19} 预算的基线 Loss 由 2.998935 升至 3.367161。

能力分解的 17.02% 参数关联份额随群体筛选和时间起点变化，可出现负值。预测分别呈现条件模型区间、四模型中心范围及 $\rho=1、0.5、0$ 的外生情景中心，三者对应不同不确定性来源。

表 20 汇总已实际运行的权重、支持域、成本和预测结构敏感性。参数抽样带的宽窄应与机制情景和群体选择分开解读。

表 20 关键建模选择的综合灵敏度

问题与变化因素	已检查范围	核心输出变化	敏感程度	解释与界限
Q1 质量表示	W0、W1、五维 DQ0	W0/W1 七域次序相同；DQ0 反转 arxiv/commoncrawl	用途解释敏感	规则分非训练质量真值
Q1 配比规模与支持	1M、60M、1B；A12—A15 估算	中心化误差比约 0.80、0.89、3.11；估算 2.35/2.27	跨规模高度敏感	只对已检验规模与近邻支持作判断
Q2 整轨迹参数	200 次联合重抽样	五参数条件分位窄，边界触及 0 次	源内数值低敏感	不覆盖来源或结构不确定性
Q3 质量成本	指数、幂、对数	10^{19} 时条件 Q 约 0.675/0.507/1.000	机制高度敏感	收益来自半合成条件搬运
Q3 上下文与参数	2048 至 131072；200 个联合参数向量	低预算 Loss 2.998935→3.367161；参数带很窄	成本敏感、参数数值低敏感	长上下文收益未入目标
Q3 支持与配比	D 上界压力、513 个有限候选	高预算 Loss 平台随 D 上界变化；最小均值候选仍 3 域恶化	支持/用途敏感	现实供应、跨来源配比效应未识别
Q4 群体与家族	已知家族、严格许可、较晚起点	参数关联份额从 17.02% 可变为负	高度敏感	描述份额非因果比例
Q4 预测结构与放缓	四模型； $\rho=1/0.5/0$	2027 中心范围 52.17—83.77；条件中心 79.76/77.93/76.11	长期模型/情景敏感	不同范围无共同概率覆盖

综合而言，B1 参数传播在既定曲面内较稳定；质量收益搬运、支持域选择、家族筛选和长期模型结构对解释影响更大。

七、模型评价

7.1 模型的优点

模型首先以公开规则处理 22 项异构质量信号，同时保留五维画像，使综合评分可复算且可解释。统计分歧与语义目标取舍分别识别，避免凭相关符号判断指标冲突。

验证设计尊重资料依赖结构：配比模型留出训练运行并报告 13 域结果，标度律留出完整轨迹与前向块，资源优化将解析解、数值核验及活跃约束并列。

跨问传递始终连同量尺与支持域报告。B7 质量斜率作为半合成校准，配比规模迁移由留出检验裁定；能力预测把条件区间、模型范围和外生增长情景分别呈现。

7.2 模型的缺点

主要限制来自资料和量尺。Q_full 的部分方向取决于评价用途；A、B 表缺少同运行质量—配比—损失键，真实质量弹性与跨来源配比系数尚未识别。B1 外部训练来源和共同 Loss 锚需进一步核对，Q3 最优配置只针对题设成本代理及统计支持域。

C8 训练 D 记录不足，参数关联与调整残差不能分解为完整规模和纯技术效应；Q4 增长情景依赖外生路径及固定 D。能力观测止于 2025 年 3 月，距预测原点 560 天，长期区间缺同期限验证。这些限制决定了条件配置与前沿预测的应用范围。

八、模型改进与推广

8.1 模型的改进

后续可增加同文本人工目标标注与配对训练干预，检验 Q_full 用途目标是否对应真实训练收益。对长度、数字比例和 DSIR 相似性等指标，可按语言、领域和任务设置参考画像，再用新增样本检验排序稳定性。

标度律研究需要补齐验证集、tokenizer 和训练阶段信息，建立跨附件共同 Loss 锚；质量与配比系数应在多规模真实训练中配对估计。资源优化还需实际数据供应、处理成本和长上下文收益。

能力预测应补充 2025 年 3 月之后的同口径逐任务评测、训练 token 和历史榜单快照。积累足够长的序列后，分别进行时间外推、家族外检验，并在 12 与 24 个月同期限校准区间。

8.2 模型的推广

可迁移的是分析顺序：先确定指标方向与用途，再核对资源响应的量尺和支持域，随后给出预算成本与活跃约束，最后分别处理预测参数、模型与情景不确定性。新任务仍需重估具体评分权重、幂律系数和成本。

本题形成规则明确的 22 项质量分、1M 范围内的局部配比响应、B1 内部的规模—数据替代曲面，以及题设成本下的条件资源配置。能力前沿预测由 C8 同口径任务分数独立完成，并随观测更新继续检验。

参考文献

- [1] Hoffmann J, Borgeaud S, Mensch A, et al. Training Compute-Optimal Large Language Models. arXiv:2203.15556, 2022. <https://arxiv.org/abs/2203.15556>, 访问日期 2026-09-25。

- [2] Aitchison J. The Statistical Analysis of Compositional Data. Journal of the Royal Statistical Society Series B, 44(2):139–177, 1982. <https://doi.org/10.1111/j.2517-6161.1982.tb01195.x>。
- [3] Biderman S, Schoelkopf H, Anthony Q, et al. Pythia: A Suite for Analyzing Large Language Models Across Training and Scaling. arXiv:2304.01373, 2023. <https://arxiv.org/abs/2304.01373>, 访问日期 2026-09-25。
- [4] Künsch H R. The Jackknife and the Bootstrap for General Stationary Observations. The Annals of Statistics, 17(3):1217–1241, 1989. <https://doi.org/10.1214/aos/1176347265>。
- [5] 中国研究生数学建模竞赛组委会. 2026 年 F 题题面及配套数据说明, 竞赛附件, 2026。
- [6] opendatalab. SlimPajama Meta-rater 数据卡, <https://huggingface.co/datasets/opendatalab/SlimPajama-Meta-rater/blob/main/README.md>, 访问日期 2026-09-25。数据卡说明字段族, 不证明比赛摘录的每项生成版本。
- [7] Liu Q, Zheng X, Muennighoff N, et al. RegMix: Data Mixture as Regression for Language Model Pre-training. arXiv:2407.01492, 2024. <https://arxiv.org/abs/2407.01492>, 访问日期 2026-09-25。本文未照搬其模型系数。

附录 A 完整质量信号处理

表 A1 分别列出全部 22 项字段族的原始解释角色、进入 Q_full 的规则和使用限制。逐字段目标与权重以支撑表 Q_FULL_FIELD_CONTRACT_v1.csv 为准。22 项均进入 W0 等权综合评分；但原始值并非都具有越大越好的含义，转换后的效用也不能直接充当已识别的训练质量效应。19 条不完整记录以中性 0.5 暂补并报告覆盖数；列表原分量保留，域级分布和有效样本数在支撑表提供。

表 A1 22 项信号的原始角色、Q_full 处理与解释限制

序号及字段族	原始含义及解释角色	Q_full 中的处理	限制
1. fineweb_edu	教育价值原评分	A1 固定中秩分位；正向效用，作为 1 项计入 W0	标注描述；非训练因果证据
2. fluency_en	流畅与不流畅 logit 差	A1 固定中秩分位；正向效用，作为 1 项计入 W0	英语适用；非跨语言真值
3. modernbert_cleanliness	清洁等级的概率加权值	A1 固定中秩分位；正向效用，作为 1 项计入 W0	模型标注；非训练因果证据
4. modernbert_readability	可读等级的概率加权值	A1 固定中秩分位；正向效用，作为 1 项计入 W0	模型标注；非训练因果证据
5. modernbert_reasoning	推理复杂度等级	取 A1 固定中秩分位及参考目标接近效用，作为 1 项计入 W0	用途依赖；无通用原值方向
6. modernbert_professionalism	专业性等级	取 A1 固定中秩分位及参考目标接近效用，作为 1 项计入 W0	用途依赖；无通用原值方向

序号及字段族	原始含义及解释角色	Q_full 中的处理	限制
7. dsir_books	书籍目标域相似性	取 A1 固定中秩分位及参考目标接近效用，作为 1 项计入 W0	原始尺度未核，受长度混杂
8. dsir_wiki	百科目标域相似性	取 A1 固定中秩分位及参考目标接近效用，作为 1 项计入 W0	与书籍列近重复，尺度未核
9. dsir_math	数学目标域相似性	取 A1 固定中秩分位及参考目标接近效用，作为 1 项计入 W0	与书籍列近重复，尺度未核
10. qurater	四项原始质量评级	四面向各取 A1 分位和参考目标接近效用，平均为 1 项计入 W0	原四面向仍需分别解释
11. ad_en	无广告与有广告 logit 差	A1 固定中秩分位；正向效用，作为 1 项计入 W0	广告目标依赖用途和语言
12. rps_doc_word_count	文档词数	先作 $\log(1+x)$ ，再取 A1 固定中秩分位及参考目标接近效用，作为 1 项计入 W0	长度不是单调质量
13. rps_doc_num_sentences	文档句数	先作 $\log(1+x)$ ，再取 A1 固定中秩分位及参考目标接近效用，作为 1 项计入 W0	长度不是单调质量
14. rps_doc_unigram_entropy	一元词分布熵	取 A1 固定中秩分位及参考目标接近效用，作为 1 项计入 W0	熵基数未核；用途依赖
15. rps_doc_frac_unique_words	不重复词比例	取 A1 固定中秩分位及参考目标接近效用，作为 1 项计入 W0	语言和用途敏感
16. rps_doc_frac_no_alph_words	非字母词比例	取 A1 固定中秩分位及参考目标接近效用，作为 1 项计入 W0	代码等语料用途敏感
17. rps_doc_frac_chars_top_2gram	最高频二元组字符比	取 A1 固定中秩分位及参考目标接近效用，作为 1 项计入 W0	原始超界值不裁剪；来源链未全核
18. rps_doc_frac_chars_top_3gram	最高频三元组字符比	取 A1 固定中秩分位及参考目标接近效用，作为 1 项计入 W0	原始超界值不裁剪；来源链未全核
19. rps_lines_uppercase_letter_fraction	大写字母比例	取 A1 固定中秩分位及参考目标接近效用，作为 1 项计入 W0	语言及排版用途敏感

序号及字段族	原始含义及解释角色	Q_full 中的处理	限制
20. rps_lines_ending_with_terminal_punctution_mark	行尾终止标点比例	取 A1 固定中秩分位及参考目标接近效用，作为 1 项计入 W0	文体和用途敏感
21. rps_lines_numerical_chars_fraction	数字字符比例	取 A1 固定中秩分位及参考目标接近效用，作为 1 项计入 W0	题材及用途敏感
22. rps_doc_mean_word_length	平均词长	取 A1 固定中秩分位及参考目标接近效用，作为 1 项计入 W0	语言及分词方式敏感

附录 B 逐领域验证

表 B1 列出 1M 留出运行的全部 13 域原尺度 RMSE，与图 5 和表 4 来自相同冻结预测。总体改善并未消除领域间误差差异。

表 B1 1M 留出逐领域预测误差

验证领域	M0 RMSE	M1 RMSE	M1/M0
arxiv	0.7969	0.5888	0.7389
freelaw	0.7378	0.4806	0.6514
pubmed_central	0.8408	0.5312	0.6318
wikipedia_en	0.5464	0.2957	0.5412
dm_mathematics	1.5393	1.1605	0.7539
github	0.9440	0.6129	0.6492
stackexchange	0.6759	0.4487	0.6639
gutenberg_pg_19	0.4490	0.2564	0.5712
pile_cc	0.3206	0.1532	0.4778
ubuntu_irc	0.9994	0.6487	0.6490
hackernews	0.3366	0.1900	0.5647
pubmed_abstracts	0.5708	0.2626	0.4601
uspto_backgrounds	0.5104	0.2725	0.5340

附录 C 求解与复现说明

配比模型以训练配比的正交坐标拟合各响应域，冻结参数后检验留出；跨规模只比较中心化形状，支持分类只用训练几何。质量参考、方向与权重不依赖留出 Loss。

标度律采用轨迹等权的有界非线性最小二乘，保存验证索引并按整轨迹重抽样。资源基线用式（19）；质量情景固定 Q 消元，再检查端点与局部谷，保留失败起点。

前沿由模型身份和原始任务组得分构造；分解沿用同一分位插值权重。滚动预测只用当时可用窗口；条件区间用固定模型与残差块，模型范围另算。原件、参数、输出和图表以哈希关联，支撑材料提供索引及核对程序。

模型参数与机器结果按冻结产物引用，计算用全精度，正文四舍五入；用印刷参数回代产生的末位差异不代表模型改变。

支撑目录保留评分、外推、情景、图表及论文构建程序，列出源文件和机器输出 SHA256；既有 M1 与 Q2/Q3/Q4 脚本及摘要均保留。

AI 辅助使用说明：证据核对、文字整合、排版及一致性检查代码使用 Codex（当前会话模型标识 GPT-6，开发机构 OpenAI）辅助。模型版本发布日期未获独立核验；历史阶段工具版本与日期须由参赛队按原始记录补充。参赛队负责核对最终提交内容。

附录 D 补充稳健性与探索性诊断

为保留完整证据链，列出未被正文主模型采用、但帮助确定表示方式的训练内诊断。这些值在既有附件上计算，未作为留出模型验收或跨来源运输依据。完整逐行数据与绘图源可由项目支撑材料核对；此处只呈现读者理解取舍所需的数量关系。

表 D1 训练内探索诊断与使用边界

诊断对象	本地结果	解释作用	正文主结论中的地位
五维质量首主成分	解释方差 48.11%；“无广告单独成组”在 9 层中仅 3 层复现	不以单一主成分取代五维画像	探索性结构检查
十三领域响应的首主成分	解释方差 22.78%；平均响应与主成分排序 Spearman 约 0.545	单一响应轴不能代表所有领域	仅供表示选择参考
训练配方域对	78 对中 Pearson 负相关 24 对、Spearman 负相关 29 对	领域异质性要求保留十三域响应	训练内诊断，非留出改善

Q1 经验支持分类为：A6/A8 各 256 组配比的 IN/NEAR/OUT 数量为 2/252/2，A10 的 64 组为 15/46/3；域外样本不足以单独估计稳定误差。Q2 在 B2/B4/B5 的来源内中心化形状比分别约 0.855/0.437/0.555。Q4 原非正参数趋势使旧放缓路径重合，正文另用已声明的外生正增长参照。